

项目说明 · 离线 MVP

# 基于需求匹配的 亲子游戏 Agent 推荐系统

不用爬虫、不用训练、不用数据库的最小可行设计

## 核心思路

系统不声称识别用户的永久“思想派别”或人格，而是通过三个具体情景判断用户当前更关注的处理方向，再推荐一个主 Agent 和一个备选 Agent。这样保留了立场与需求匹配的产品价值，同时让推荐过程更透明、更可解释。

### 3 道题

约 1 分钟完成

### 5 个 Agent

覆盖五类当前需求

### 0 模型调用

推荐阶段完全离线

## 摘要

通用对话助手通常采用相近的回应方式，难以同时适应不同家长的目标：有人想立即建立规则，有人更重视协商，有人需要先修复关系，也有人正面临充值、账号或人身风险。本项目将推荐问题压缩为三道情景题和一套固定计分规则，输出可解释的主推荐、备选推荐和安全提醒。当前实现是一个可双击运行的静态网页；未来只需把推荐结果对应的 `system_prompt` 交给任意大模型，即可进入真实对话。

# 1. 问题与设计目标

亲子游戏管理并不是单一问题。同一句“孩子玩游戏太久了”，背后可能对应边界执行、共同协商、关系冲突、作息观察或现实风险。若所有用户都进入同一个通用 Agent，回答很容易变成笼统劝说；若系统直接给用户贴“强硬派”“放任派”等标签，又会产生误判、冒犯和隐私风险。

产品定位

推荐的是“此刻更需要哪一种帮助”，而不是判断用户“本质上属于哪一类人”。结果只基于三道题，用户可以重新测试，也可以主动切换 Agent。

## 1.1 四个最小化原则

| 原则  | 具体做法                             |
|-----|----------------------------------|
| 轻量  | 只使用三道选择题，不要求注册或填写长问卷。            |
| 可解释 | 每个选项对应固定加分，结果页明确说明推荐原因。          |
| 可运行 | 静态 HTML 离线运行，不依赖数据库、爬虫或模型 API。   |
| 可扩展 | Agent 卡片和题目保存在配置中，未来可以接入后端和真实模型。 |

## 1.2 从进入到对话的完整流程



本项目当前实现到“展示推荐”这一步。接入真实对话时，后端只需根据 Agent ID 读取系统提示词，再调用任意模型；推荐层本身无需调用模型。

## 2. 三道情景题与推荐算法

三道题分别观察“先关注什么”“希望怎样行动”和“什么结果算有效”。相比直接询问抽象立场，具体情景更容易得到稳定且可理解的选择。

| 题目    | 情景         | 判断内容  | 设计目的   |
|-------|------------|-------|--------|
| 第 1 题 | 连续几天超过原计划  | 当前关注点 | 确定问题入口 |
| 第 2 题 | 到了结束时间仍不愿停 | 行动偏好  | 确定处理方式 |
| 第 3 题 | 一周后希望出现的变化 | 目标结果  | 确定最终期待 |

表 1 三道题覆盖关注、行动和结果三个层面。

### 2.1 计分规则

- 第 1 题和第 3 题：主要 Agent 加 4 分，相近 Agent 加 1 分。
- 第 2 题：主要 Agent 加 3 分，相近 Agent 加 1 分。
- 累计得分最高者为主推荐，除主推荐外得分最高者为备选。
- 最高分并列时，依次采用第 3、2、1 题所选项的主要 Agent。

初始化五个 Agent 得分为 0

遍历三道题的用户选择并累加固定分数

若风险选项次数 >= 2：主推荐 = 游戏风险处理助手

否则：主推荐 = 得分最高 Agent

若最高分并列：依次参考第 3、2、1 题

备选推荐 = 除主推荐外得分最高 Agent

### 2.2 风险覆盖

**风险不是普通偏好**

三题中至少两次选择充值、账号、陌生人或严重失控等风险选项时，系统直接推荐风险处理助手；只选择一次时，保留普通推荐，同时额外显示风险入口。暴力、自伤或即时人身危险应转向可信的线下支持或当地紧急服务。

### 3. 五个 Agent 的角色卡片

每张 Agent 卡片包含适用情形、核心立场、沟通语气、典型产出、安全边界和 `system_prompt`。模板负责保证稳定的角色行为，用户的具体情况则在后续对话中补充。

| Agent    | 核心任务           | 语气    | 典型产出           |
|----------|----------------|-------|----------------|
| 规则落地教练   | 建立清晰且稳定执行的家庭规则 | 坚定、直接 | 一周规则、违约后果、复盘清单 |
| 亲子协商搭档   | 共同制定协议并处理例外    | 平等、温和 | 协商开场白、家庭游戏协议   |
| 关系修复向导   | 先降温，再恢复有效沟通    | 共情、克制 | 降温步骤、倾听提纲      |
| 理性观察规划师  | 记录真实影响后再决定干预   | 冷静、客观 | 七日观察表、最小调整方案   |
| 游戏风险处理助手 | 应对充值、账号与人身风险   | 镇定、清楚 | 止损步骤、证据与风险清单   |

表 2 五个 Agent 分别覆盖不同的当前需求。

#### 3.1 为什么不使用纯动态生成

第一版采用固定 Agent 卡片，而不是在每次推荐后动态生成整个角色。固定卡片更容易测试、解释和审查安全边界，也便于用户收藏与切换。后续可以把称呼、语气强度和家庭情境作为参数，但不应动态删除基本安全规则。

#### 3.2 为什么提供备选 Agent

三个问题只能完成粗粒度路由，无法代表完整家庭情况。展示备选 Agent 能承认这种不确定性，也让用户保留控制权。如果主推荐“聊起来不对味”，用户无需重新填写全部信息即可切换。

角色一致性的底线

贴合用户立场不等于无条件附和。所有 Agent 都必须区分事实、推测和情绪，不捏造名人、研究或政策，也不把单次行为扩大成永久判断。

## 4. 系统实现与安全边界

当前版本由一个静态页面和一个配置文件组成。网页包含问卷交互、固定计分、风险覆盖、结果展示、提示词复制和重新测试。配置文件保存三道题、分数、五张角色卡片与系统提示词。

### 4.1 文件结构

| 文件                    | 作用                    |
|-----------------------|-----------------------|
| code/index.html       | 完整离线演示，包含问卷、计分和结果页。   |
| code/config.json      | 题目、分数、Agent 卡片与系统提示词。 |
| paper/main.typ        | 本报告的可编辑 Typst 源文件。    |
| results/validation.md | 构建、逻辑和安全检查记录。         |

演示页面为了支持直接双击，在 HTML 中内置了一份与配置相对应的数据。真实产品应由后端统一读取配置，并在服务端保存模型 API Key，避免把密钥放进浏览器。

### 4.2 固定安全边界

**禁止伤害**  
不建议体罚、羞辱、威胁、剥夺睡眠、毁坏设备或强制隔离。

**禁止侵入**  
不提供秘密监控、盗号、破解设备或其他违法侵入建议。

**禁止捏造**  
不虚构名人观点、研究结论、平台政策或退款承诺。

**保护隐私**  
不收集姓名、学校、住址、证件、账号密码等无关信息。

**最小必要干预**  
普通游戏超时不直接诊断为“游戏成瘾”。系统优先给出可逆、可观察、可复盘的短期方案，例如一周试行规则，而不是永久性或极端措施。

## 5. 验证、运行与下一步

### 5.1 已完成验证

| 检查项                     | 状态 |
|-------------------------|----|
| 配置可解析，题目数为 3，Agent 数为 5 | 通过 |
| 网页 JavaScript 语法检查      | 通过 |
| 五条同类答案路径均命中预期 Agent     | 通过 |
| 浏览器走通完整问卷并检查控制台错误       | 通过 |
| PDF 编译、文本提取与逐页渲染检查      | 通过 |
| 私用 ZIP、密钥和本机绝对路径不进入 Git | 通过 |

### 5.2 最小运行方式

1. 打开项目的 code/ 目录。
2. 双击 index.html。
3. 回答三道情景题并查看主推荐和备选推荐。
4. 展开系统提示词，复制给任意大模型即可继续对话。

也可以在 code/ 目录运行 `python -m http.server 8000`，再访问 `http://127.0.0.1:8000/index.html`。

### 5.3 下一阶段只记录四项数据

第一版上线后，只需匿名记录：推荐结果、是否切换 Agent、对话轮数、用户满意度。等积累真实使用数据后，再调整题目和分数；在此之前，不需要爬取社区内容，也不需要训练分类模型。

#### 结论

这个 MVP 的价值不是算法复杂，而是把“谁适合和我聊”变成一个透明、可控、可验证的产品流程。三道题、五张卡片和固定计分已经足够验证用户是否愿意接受并使用这种推荐。