

产品原型 · 第二版

基于需求匹配的 亲子游戏 Agent 推荐系统

从固定问卷升级为对话识别与离线回退的双入口系统

核心变化

V2 允许用户先自然描述最近发生的事情，通过 2-3 轮中性追问形成临时需求画像。模型只整理画像，最终 Agent 选择、置信度门槛、风险覆盖与紧急分流均由本地代码决定。第一版三题问卷仍完整保留。

2-3 轮对话

够明确即可提前结束

5 个 Agent

本地确定性映射

3 层回退

模型、关键词、问卷

摘要

亲子游戏管理中的“我该怎么办”可能指向规则执行、共同协商、关系修复、作息观察或现实风险。V1 用三道情景题完成透明路由；V2 在不爬取社区数据、不训练分类器、不增加数据库的前提下，加入自然对话入口。服务端调用模型输出五维需求分数、置信度、摘要和风险标志，再由固定代码选择主推荐和备选。缺少密钥或网络异常时，系统自动使用本地关键词并保留问卷入口。该架构把模型的语言理解能力与可审计的产品规则分开，既改善体验，也避免让模型直接给用户贴标签或决定安全动作。

1. 从第一版到第二版

第一版已经证明一个很小的闭环可以运行：三道情景题、五张 Agent 卡片、固定加分和一个可解释的结果页。它的优点是离线、稳定、几乎零成本；缺点是用户必须把复杂家庭情况压缩成三个选项，产品也很难表现出“它在逐步理解我”。

V2 的产品定位

推荐的是“此刻更需要哪一种帮助”，不是识别用户“本质上属于哪一类人”。画像只在当前请求中使用，不需要姓名、学校、住址、账号密码或永久思想标签。

1.1 双入口，而不是替换 V1



1.2 四个设计原则

原则	具体做法
少依赖	不爬虫、不训练、不建数据库；后端只用 Python 标准库。
可解释	模型产出画像，本地规则负责最终推荐，结果展示主项、备选和原因。
可回退	没有密钥或网络时使用本地关键词；V1 问卷永久可用。
可审计	风险扫描先于模型调用，服务端不记录原始对话，客户端助手文本不被信任。

2. 对话识别架构

V2 的核心不是“让大模型自由选择一个 Agent”，而是让它完成一个窄任务：把用户当前叙述压缩成结构化临时画像。推荐算法仍然是普通、可测试的代码。

2.1 受控数据流



2.2 模型允许输出的画像

```

{
  "scores": {
    "firm_boundary_coach": 78,
    "collaborative_negotiator": 45,
    "relationship_repair_guide": 30,
    "evidence_based_planner": 66,
    "spending_risk_helper": 5
  },
  "confidence": 0.82,
  "summary": "当前先需要建立规则，并观察睡眠和作业影响。",
  "risk_level": "none",
  "risk_signals": []
}
  
```

模型没有 `selected_agent` 字段。即使返回额外字段，本地归一化也会丢弃；五类分数被限制在 0 到 100，置信度被限制在 0 到 1，风险等级只接受规定枚举。

2.3 追问和结束条件

- 第 1 轮一定继续，用固定问题区分事实、担忧和已经尝试的方法。
- 第 2 轮若置信度至少 0.65，且第一名领先第二名至少 10 分，即可推荐。
- 若仍不明确，第三轮询问未来一周最想改善的一件事和已确认风险。
- 第 3 轮必须结束；证据不足时明确标记为临时推荐，而不是继续无限追问。

3. 确定性推荐与离线回退

3.1 本地匹配规则

系统按五维分数排序，最高分为主推荐，第二名为备选。模型不能覆盖本地风险判断；已经发生的充值、账号、陌生人诱导或诈骗勒索等信号会强制把游戏风险处理助手放在第一位。

先做本地风险扫描

若存在即时人身危险：停止普通推荐并提示线下即时支持

否则取得模型画像或本地关键词画像

归一化五类分数、置信度与风险枚举

若已确认消费或账号风险：主推荐 = 游戏风险处理助手

否则：主推荐 = 最高分 Agent，备选 = 第二高 Agent

第 2 轮达到置信度和分差阈值即可结束；第 3 轮必须结束

3.2 三层可用性

层级	条件	用户体验
模型画像	后端密钥与网络可用	自然描述，通常两轮完成推荐。
本地关键词	模型不可用但描述清楚	不上传描述，直接给出临时匹配。
V1 问卷	任何环境均可用	三道固定问题，透明计分，完全离线。

3.3 V1 问卷仍然有价值

V1 不是被淘汰的旧代码，而是低成本、可解释、可复现的稳定入口。用户不愿发送自由文本、模型服务不可用，或本地关键词无法拉开差距时，都可以切换到问卷。原始页面完整保存在 code/v1.html，V2 页面也继续复用相同题目和 Agent 卡片。

配置单一来源

code/config.json 保存阈值、关键词、三道题和五张卡片；code/tools/bundle_config.py 生成浏览器可用的 config.bundle.js。自动测试会检查两者逐字一致，避免手工维护两份配置。

4. 五个 Agent 与角色边界

每张 Agent 卡片包含适用情形、核心立场、沟通语气、典型产出、安全边界和系统提示词。对话画像只负责路由，不动态重写这些底线。

Agent	核心任务	语气	典型产出
规则落地教练	建立清晰且稳定执行的家庭规则	坚定、直接	一周规则、后果、复盘清单
亲子协商搭档	共同制定协议并处理例外	平等、温和	协商开场白、家庭游戏协议
关系修复向导	先降温，再恢复有效沟通	共情、克制	降温步骤、倾听提纲
理性观察规划师	记录真实影响后再决定干预	冷静、客观	七日观察表、最小调整
游戏风险处理助手	应对充值、账号与接触风险	镇定、清楚	止损步骤、证据与风险清单

表 1 五个 Agent 覆盖不同的当前需求。

4.1 为什么保留备选 Agent

两三轮对话仍然只是粗粒度路由。展示备选能承认不确定性，也让用户保留控制权。如果主推荐不合适，用户无需重新描述全部情况即可切换。

4.2 贴合不等于附和

不贴永久标签

只描述当前需求，不输出思想派别、人格、诊断或身份判断。

不捏造依据

不虚构名人观点、研究数据、平台政策或退款承诺。

不鼓励伤害

不建议体罚、羞辱、威胁、毁坏设备或剥夺睡眠。

不替代专业支持

不把普通超时诊断为成瘾；紧急风险优先转向线下支持。

5. 系统实现与安全设计

5.1 文件结构

文件	作用
code/index.html + app.js	V2 双入口网页、对话、问卷和结果展示。
code/v1.html	第一版原始离线问卷，可独立使用。
code/server.py	静态服务、健康检查和对话接口。
code/llm_client.py	服务端模型调用、JSON 响应和安全错误处理。
code/recommendation.py	画像归一化、风险扫描、确定性推荐与回退。
code/prompts/probe-system.txt	限制模型只输出临时需求画像。
code/config.json	Agent、题目、阈值、关键词的唯一配置来源。
code/tests/	接口、映射、安全和配置一致性自动测试。

5.2 输入与密钥边界

- 单条回答最多 800 字，最多三轮，HTTP 正文也有总大小限制。
- API Key 只从服务端环境变量读取，不写进 HTML、JavaScript 或配置文件。
- HTTP 服务关闭请求日志，不保存原始对话或模型错误正文。
- 客户端发送的 assistant 文本不被信任。后端只提取用户回答，并重新插入服务端固定问题后调用模型。
- 紧急关键词扫描发生在任何远程请求之前；模型不可用也不影响紧急分流。

5.3 风险表达不是简单查词

本地扫描区分“已经发生”“只是担心”和否定表达。例如“没有自伤情况”不应触发紧急分流；“担心会不会充值”只进入观察，而“已经偷偷充值”才强制进入风险处理。普通关键词算法不做诊断，只负责把明显风险放到更安全的处理路径。

最小必要干预

系统优先给出可逆、可观察、可复盘的短期方案。模型和 Agent 都不得把一次行为扩大成永久结论，也不得因为“更符合用户立场”而取消事实核查与安全边界。

6. 验证、运行与下一步

6.1 已完成验证

检查项	状态
17 项自动测试：接口、配置、五类映射与安全规则	通过
前后端 JavaScript 与 Python 语法检查	通过
真实 HTTP：主页、健康接口、离线回退、紧急分流	通过
真实模型：第一轮继续追问，第二轮完成推荐	通过
模型不直接选择 Agent，客户端助手文本不进入模型	通过
PDF 编译、文本提取和逐页渲染检查	通过

6.2 运行方式

完全离线：双击 code/index.html，使用本地关键词或三题问卷；原始第一版为 code/v1.html。

启用对话画像：

```
$env:OPENROUTER_API_KEY = "你的密钥"
# 可选: $env:OPENROUTER_MODEL = "openai/gpt-4.1-mini"
python code\server.py
# 浏览器打开 http://127.0.0.1:8000/
```

密钥只应存在于启动服务的进程环境中。若健康接口判断模型未配置，前端会直接显示离线模式，不会假装完成智能识别。

6.3 下一步

下一版不需要立刻训练模型。优先匿名记录推荐结果、是否切换、完成轮数和满意度，再判断问题出在画像、阈值、Agent 卡片还是用户界面。只有当真实误配样本足够多时，才值得调整提示词、关键词或考虑更复杂的学习算法。

结论

V2 用很小的工程增量把“填问卷”升级为“它逐步理解我”，同时保留了 V1 的离线稳定性。模型负责理解语言，普通代码负责作决定，风险规则拥有最高优先级。这比纯模板更自然，也比让模型自由推荐更可控。