

大语言模型行为指纹：从 OpenCode Go、Codex GPT-5.x 到 ChatGPT 网页版

3099404236 Researcher^{1,2}

¹Independent Researcher

本研究复现并扩展“单 token 输出分布”行为指纹方法，公开四组共 4,000 个正式短回答：OpenCode Go 五端点同日小基准、PAMELA 公共图谱跨供应商复测、Codex 六种 GPT-5.x 运行配置，以及 ChatGPT 网页版 8x5 目标指纹。固定协议下，短答案分布表现出显著的短期重复性与候选间区分度；Hy3 与精确 MiMo-V2.5 参考在公共库复测中排名第一；网页版目标在 161 与 176 模型参考库中均稳定地以 GPT-5.4 为最近邻。本文同时展示硬阈值误接受、checkpoint 错配、隐藏推理、包装差异和未知模型强制归类等失败模式。结论仅支持行为相似性和封闭候选集识别，不构成底层权重或后台路由的身份证明。

LLM fingerprinting | model verification | Jensen-Shannon divergence | API audit | reproducibility

https://github.com/3099404236/llm-behavioral-fingerprints

研究问题与结论边界

在转售、聚合和动态路由的模型服务中，客户端通常只能看到模型名称和输出文本，无法直接检查权重。Bruckner 提出的“单 token 输出分布”方法利用一个稳定但常被忽视的现象：面对“说一个随机数字”“说一种随机颜色”等低熵问题，不同模型不会均匀随机，而会反复偏好少数答案；把多次回答聚合成分布后，这种偏好可成为低成本行为指纹 [1]。

本研究关心三个更具体的问题：

1. 同一端点在短时间内能否重复产生相近指纹？
2. 市面公共指纹库能否迁移到另一供应商、另一包装或网页宿主？
3. 当目标不在参考库内，最近邻与固定阈值会怎样误导判断？

一句话结论。方法是有效的行为测量工具，但不是密码学身份证。它可以支持“在固定协议下可重复”“在这些候选中最像某模型”，不能单独证明后台真实模型标识。

方法

从回答到指纹。

对模型运行配置 M 、探针单元 c 和规范化答案 x ，收集 n_c 次回答并构造经验分布

$$\hat{p}_{M,c}(x) = \frac{N_{M,c,x}}{n_c}.$$

两份指纹在同一单元上的距离使用 base-2 Jensen-Shannon divergence (JSD) [2]：

$$\text{JSD}(P, Q) = \frac{1}{2} \text{KL}(P \parallel R) + \frac{1}{2} \text{KL}(Q \parallel R), \quad R = \frac{P + Q}{2}.$$

JSD 位于 $[0, 1]$ ：0 表示经验分布完全一致，1 表示支持集不重叠。多单元指纹取可比较单元的平均 JSD。最近邻识别选择平均距离最小的参考；身份验证则需另行校准拒识阈值。

四组实验。

实验 A、C 使用 llm-fingerprint-detector 的规范化与统计实现 [3]；实验 B、D 使用 PAMELA 原始八格协议和冻结参考 [4], [5], [6]。每次比较都采用完整答案分布，而不是只比较众数。

如何检验方法本身是否可靠。

我们把可靠性拆成五层：

- **重复性**：不重叠的同模型样本距离是否小；
- **区分度**：同模型距离是否系统性小于跨模型距离；
- **识别稳定性**：随机分半、删轮或删除后 top-1 是否保持；
- **开放集安全性**：是否允许 unknown，而不是永远强行选择最近模型；
- **协议有效性**：推理模式、system 角色、temperature、token cap 与包装是否和参考一致。

其中前三层可由内部数据检验；后两层需要实验设计和外部参考，不能被一个高准确率数字替代。

实验	对象	单元	正式回答	主要验证
A 同日小基准	OpenCode Go 五端点	8	1,800	重复性、跨端点区分、原阈值
B 公共库复测	Hy3、MiMo、DeepSeek	8	720	跨供应商迁移、checkpoint 对齐
C Codex 配置	Sol、Terra、Luna、5.5、5.4、5.4 mini	8	1,440	固定/随机分半、删单元
D 网页目标	ChatGPT Web	8	40	161/176 库排名、删轮、删单元

表1 四组实验总览。所有“模型”均按当时可见端点或运行配置 ID 记录。

OpenCode Go mean JSD

	Ox	Muse	Hy3	MiMo	DeepSeek
Ox	0.060	0.373	0.346	0.381	0.359
Muse	0.373	0.105	0.464	0.372	0.303
Hy3	0.346	0.464	0.072	0.303	0.302
MiMo	0.381	0.372	0.303	0.176	0.290
DeepSeek	0.359	0.303	0.302	0.290	0.120

Lower JSD means more similar; diagonal = within-profile split/run distance.

图1 OpenCode Go 模型级平均 JSD。对角线为同端点三轮之间的平均距离，非对角线为跨端点距离。

实验 A：OpenCode Go 五端点同日小基准

五个端点各采集 3 份独立指纹，每份为 8 格 × 15 次，共 1,800 个正式请求；全部成功。原工具使用 $JSD \leq 0.25$ 为 match、 $0.25-0.35$ 为 uncertain、 >0.35 为 mismatch。

15 个同模型配对全部进入 match；90 个跨模型配对中有 1 个进入 match、52 个 uncertain、37 个 mismatch。错误接受发生在 MiMo-V2.5 第 2 轮与 DeepSeek V4 Flash 第 1 轮之间，JSD 0.233835。连续距离在本批数据上的 AUC 为 1.0，同模型最大距离 0.197890，跨模型最小距离 0.233835；但这两类比较共享指纹，不能把样本内 AUC 当作独立生产准确率。

推理协议警告.

Hy3 和 MiMo 成功关闭显式推理；Ox 与 Muse 需要 post-reasoning fallback。Muse 每个可见短答案平均报告约 386–403 个 reasoning tokens。DeepSeek 虽接受 reasoning.enabled=false，可见仅一个词的回答却平均报告

约 49–53 completion tokens。后两种情况说明指纹包含隐藏计算或服务包装，不能等价为论文定义的直接单 token 权重指纹。

硬阈值不是身份定理。 原阈值在这批数据中保留全部同模型配对，却仍错误接受一个跨模型配对。排序、间隔和拒识机制比单一阈值更有信息量。

实验 B：公共指纹库跨供应商复测

PAMELA 原研究通过 OpenRouter 采集多语言单 token 分布，并公开原始数据与软件 [4], [7]。我们冻结了两份市面参考：VerifyLLMAPI v0.3.2 的 161 模型八格图谱，以及 Dreamor 的 176 模型完整分布库。二者共享 PAMELA 数据来源，因而是两种打包/覆盖方式，不是两次独立实验。

端点	精确参考	JSD	排名	有效旧样本/格	严格结论
Hy3	tencent/hy3	0.1722	1/176	22–27	强支持跨供应商一致
MiMo-V2.5	xiaomi/mimo-v2.5	0.3364	1/176	5–11	top-1, 但旧参考稀疏
DeepSeek V4 Flash	deepseek/...	—	—	26–30	240/240 post-reasoning, 不可检验

表 2 Dreamor 176 模型库严格比较。JSD 为 8 格平均；DeepSeek 严格通道无合法样本。

对 DeepSeek V4 Flash、Hy3、MiMo-V2.5 分别按八格 × 30 次重新采样，共 720 个唯一正式样本。每格按 repetition 奇偶拆为两个 15 样本半组。

Verify 库只有 xiaomi/mimo-v2.5-pro，没有精确 MiMo-V2.5。新端点对错误 Pro 参考被拒绝；Dreamor 含精确 checkpoint 后，正确参考升至第一。这说明“同家族”或“Pro 版本”不能替代精确模型 ID。Hy3 在 Verify 的两个半组中也都排名 1/161，参考距离分别为 0.228914 和 0.218881。

DeepSeek 的 240 个新回答全部携带 reasoning trace。把它们违规纳入时，精确参考在 Dreamor 中仅排 27/176；这


个结果只能诊断当前运行时与直接采样协议差异，不能用来否定或确认模型身份。

实验 C：Codex 六种 GPT-5.x 运行配置

每个样本是全新的 `codex exec --ephemeral` 会话，在相同 low reasoning effort 和结构化输出 schema 下，一次回答 8 个独立探针。六个配置各 30 个会话，共 180 次真实调用和 1,440 个字段回答；1,439 个答案通过规范化。唯一无效项是 GPT-5.4 对中文随机数回答“七码”。

固定分半最近邻识别为 6/6。进一步以固定随机种子做 1,000 次 15/15 分半，得到 5,999/6,000 次严格识别正

Codex fixed-split JSD



Lower JSD means more similar; diagonal = within-profile split/run distance.

图 2 Codex 固定分半 JSD。对角线是同一配置前 15 次与后 15 次的距离；非对角线为两个配置的完整指纹距离。

ChatGPT Web — nearest references (8 cells × 5)




图3 ChatGPT Web 在两份共享来源参考库中的前五最近邻。虚线为 Verify 8×5 公布阈值；低于阈值只表示统计相容，不表示唯一身份。

确；999/1,000 次切分六个配置全部正确。随机猜测基线为 16.67%。同配置距离中位数 0.062752，最近冒充者距离中位数 0.269788，中位安全间隔 0.188191。

去掉任意一个探针后，重复分半正确率仍为 99.77%–100%，说明结果并非由单一题目支撑。不过 1,000 次切分复用了同一批 30 个会话，因此这是内部稳健性检查，不是 1,000 批新实验。

最接近的一对是 Sol 与 Terra（完整指纹 JSD 0.1555）；GPT-5.4 mini 的内部漂移最大（固定切分 0.1439）。这里的“身份”是模型 ID、reasoning effort、Codex 包装和 schema 的联合运行配置，不是裸 Responses API 权重。

实验 D：ChatGPT 网页版最近邻

网页版目标采用 PAMELA 八格各 5 次。38 个样本由用户控制的本地桥在单一浏览器窗口中采集：每次创建全新对话、原样发送 system 约束与 user 问题的拼接文本、严格串行，并在一次完成后静默 60 秒。出现风控后停止自动采集；最后 2 个样本由用户在两个全新网页对话中手工原样补充。最终 40/40 有效。

两库第一名均为 openai/gpt-5.4，平均 JSD 分别为 0.336206 (Verify) 和 0.318140 (Dreamor)；第二名均为 GPT-5.5，距离差分别为 0.150342 和 0.166676。每次删除一整轮样本，5/5 次第一名不变；每次删除一个题型，8/8 次第一名不变；删除含两个人工补样的第 5 轮后仍为 GPT-5.4。

Verify 的 8×5 阈值为 0.629197，对应同数据校准 EER 8.0745%。目标到 GPT-5.4 低于阈值，但另有多个候选也低于阈值，因此阈值不能完成唯一识别。更关键的是，两份参考库均未包含 GPT-5.6，网页宿主又无法提供真正的 API system 角色或 temperature 控制。

对外推荐表述。在 8×5 PAMELA 行为指纹实验中，该 ChatGPT 网页版目标在 Verify 161 模型和 Dreamor 176 模型参考库中都稳定地以 GPT-5.4 为最近邻；证据支持“行为上最像 GPT-5.4”，但不足以证明后台模型身份。

失败模式与改进路线

下一阶段最有信息量的实验不是继续扩大同日重复，而是预先冻结判定规则，在另一天对同一配置重新采集，并加入候选集之外的真实 unknown 目标。对每个模型分别估计 genuine 分布和最近 impostor 分布，才能建立可解释的拒识阈值与置信区间。

数据、隐私与可复现性

公开仓库包含采集代码、180 个 Codex 正式会话、OpenCode 原始样本、720 个公共库复测样本、40 个网页有效回答、聚合指纹、距离矩阵、随机分半结果和冻结参考。自动自检会验证 4,000 个正式回答、关键结论数字、161/176

失败模式	本研究中的例子	改进
阈值误接受	MiMo 与 DeepSeek 跨模型 JSD 0.233835	使用模型级阈值、排名间隔与盲测
checkpoint 错配	MiMo-V2.5 被拿去和 Pro 参考比较	精确版本覆盖，不继承家族参考
隐藏推理	Muse 高额 reasoning；DeepSeek 240/240 post-reasoning	无法关闭时单独建“端点联合指纹”
包装漂移	网页无真实 system 角色和 temperature	同宿主采参考或显式降级结论
开放集强制归类	库中没有 GPT-5.6，最近邻仍会给 top-1	预注册 unknown 阈值与候选覆盖检查
时间漂移	全部实验仅覆盖 2026-08-21/22	跨日至少三次复采，冻结规则后盲测

表3 从本研究直接观察到的失效方式及建议。

PAMELA 单元	ChatGPT Web 的 5 次答案分布
英文随机动物	otter × 5
英文随机词	lantern × 5
俄文随机动物	панда, выдра, лиса, тигр, коала, 各 1 次
阿拉伯文随机动物	نمر, ثعلب; 3 × فيل, 各 1 次
中文随机汉字	龔 × 2; 云、森、隶, 各 1 次
中文随机动物	海豚 × 3; 水獭、猫, 各 1 次
阿拉伯文随机字母	1 × ع; 4 × م
中文随机颜色	蓝色 × 5

表 4 网页版目标的完整经验分布。真正比较使用每格所有计数，而不只使用众数。

模型覆盖、参考 SHA-256，以及网页版公开副本中不存在私有对话 URL 或会话哈希。

API 密钥从未写入结果文件；所有采集器只从环境变量读取凭据。公开前将本机绝对路径替换为仓库相对路径，并从网页记录中删除私有 ChatGPT 对话链接与会话哈希。PAMELA 派生参考按 CC BY 归属 Tomás Bruckner；原创代码使用 MIT，原创论文和新实验数据使用 CC BY 4.0。

结论

本研究给出的答案不是简单的“指纹有效”或“指纹无效”。在受控、封闭的候选集内，分布指纹展现出很强的短期重复性和区分度；公开参考在 Hy3 和精确 MiMo checkpoint 上也显示了跨供应商价值。然而，阈值误接受、隐藏推理、宿主包装、稀疏参考和候选缺失都能让“最像谁”与“真实是谁”分离。

因此，行为指纹适合做低成本筛查、漂移监控和审计证据的一部分。可靠使用它需要不重叠样本、稳定性检验、精确参考、开放集拒识、跨日盲测和透明的协议元数据；任何缺少这些条件的 top-1 都应被写成相似性结论，而不是身份证明。

附录：探针与网页目标分布

自定义八格电池覆盖英文/中文随机数、1-10 随机数、英文字母、英文/中文颜色、英文动物，以及第八个上下文单元。OpenCode Go 使用 coin flip；Codex 使用英文城市。PAMELA 八格则固定为：英文随机动物、英文随机词、俄文随机动物、阿拉伯文随机动物、中文随机汉字、中文随机动物、阿拉伯文随机字母、中文随机颜色。

参考文献

[1] T. Bruckner, 《One Token Is Enough: Fingerprinting and Verifying Large Language Models from Single-Token Output Distributions》, *arXiv preprint arXiv:2607.10252*, 2026, [在线]. 载于: <https://arxiv.org/abs/2607.10252>

[2] J. Lin, 《Divergence Measures Based on the Shannon Entropy》, *IEEE Transactions on Information Theory*, 卷 37, 期 1, 页 145~151, 1991, doi: 10.1109/18.61115.

[3] Tosea.ai, 《llm-fingerprint-detector》. [在线]. 载于: <https://github.com/ToseaAI/llm-fingerprint-detector>

[4] T. Bruckner, *Single-token output distributions as behavioral fingerprints of large language models*. (2026 年). Zenodo. doi: 10.5281/zenodo.21278557.

[5] VerifyLLMAPI, 《Supported LLM Fingerprints: 161 Models in VerifyLLMAPI》. [在线]. 载于: <https://verifyllmapi.com/blog/supported-llm-fingerprints/>

[6] dreamor, 《LLM Fingerprint CLI》. [在线]. 载于: <https://github.com/dreamor/llm-fingerprint>

[7] T. Bruckner, 《Single-token output distributions as behavioral fingerprints of large language models — software》. [在线]. 载于: <https://doi.org/10.5281/zenodo.21278793>